Ассистент Порфирий

Диагностика 2: всё зависает

Сброс, проверка Ollama и ресурсов сервера Astra — всё в одном документе

Что происходит

Если зависает И проверочный файл без сайта, И чат («Сервер загружен, вы в очереди» — не пришло даже первое слово), то сейчас Ollama не отвечает на новые запросы — ни сайту, ни PHP напрямую.

Возможные причины: очередь Ollama забита старыми запросами от прошлых попыток; либо машине не хватает ресурсов — на одной виртуалке работают веб-сервер, FTP и модель, а у FTP тоже перестают загружаться файлы.

> Если вы делали правку контроллера из прошлой инструкции (отключение `connection_aborted()`), пока НЕ откатывайте её — она нужна для проверки. Как откатить — в конце документа.

В командах используется переменная `SITE` — путь к проекту. Строки, начинающиеся с `#`, вводить не нужно. Файлы создаются так: команда `cat > файл`, затем вставить текст, затем на новой строке нажать Ctrl+D — так копирование из PDF работает надёжно.

Шаг 1. Полный сброс

Очистить очередь Ollama, повисшие процессы PHP и устаревшие блокировки очереди сайта:

```
sudo systemctl restart ollama
sudo systemctl restart apache2
sudo systemctl try-restart php8.1-fpm
cd "$SITE" && sudo -u www-data php artisan cache:clear
```

Шаг 2. Скрипт проверки ресурсов

Скрипт `porfiry-check` сам смотрит процессор, нагрузку, память, подкачку, диск, убивало ли ядро процессы из-за нехватки памяти, состояние Ollama и FTP — и печатает короткие выводы вместо сырых цифр. Создаётся один раз, дальше запускается одной командой.

Создать скрипт: введите команду, нажмите Enter, вставьте весь текст скрипта из рамки ниже, затем нажмите Enter и Ctrl+D:

```
cat > ~/porfiry-check
```

Текст скрипта (от `#!/bin/bash` до строки `echo "ИТОГ:…)`:

```
#!/bin/bash
# porfiry-check: ресурсы сервера «Порфирия» — выводы вместо цифр.
SUM=""
say() {
  echo "$1  $2: $3"
  case "$1" in ВНИМАНИЕ|ПРОБЛЕМА) SUM="$SUM $2";; esac
}
gt() { awk -v a="$1" -v b="$2" 'BEGIN{exit !(a > b)}'; }
mem() { awk -v k="$1" '$1 == k":" {print int($2/1024)}' /proc/meminfo; }

C=$(nproc); L=$(cut -d' ' -f1 /proc/loadavg)
if ! grep -qw avx2 /proc/cpuinfo; then
  say ПРОБЛЕМА ПРОЦЕССОР "$C ядер, нет AVX2 — модель очень медленная"
elif [ "$C" -lt 4 ]; then
  say ВНИМАНИЕ ПРОЦЕССОР "$C ядра, AVX2 есть — ядер мало"
else
  say ОК ПРОЦЕССОР "$C ядер, AVX2 есть"
fi
if gt "$L" "$((C * 3 / 2))"; then
  say ПРОБЛЕМА НАГРУЗКА "$L при $C ядрах — процессор перегружен"
elif gt "$L" "$C"; then
  say ВНИМАНИЕ НАГРУЗКА "$L при $C ядрах — на пределе"
else
  say ОК НАГРУЗКА "$L при $C ядрах"
fi

MT=$(mem MemTotal); MA=$(mem MemAvailable)
if [ "$MA" -lt 1500 ]; then
  say ПРОБЛЕМА ПАМЯТЬ "свободно $MA из $MT МБ — критически мало"
elif [ "$MA" -lt 3000 ]; then
  say ВНИМАНИЕ ПАМЯТЬ "свободно $MA из $MT МБ — мало"
else
  say ОК ПАМЯТЬ "свободно $MA из $MT МБ"
fi
SU=$(( $(mem SwapTotal) - $(mem SwapFree) ))
if [ "$SU" -gt 500 ]; then
  say ВНИМАНИЕ ПОДКАЧКА "занято $SU МБ — памяти не хватает"
else
  say ОК ПОДКАЧКА "занято $SU МБ"
fi

for m in $(df -P / /var /usr /home /tmp 2>/dev/null | awk 'NR>1{print $6}' | sort -u); do
  u=$(df -P "$m" | awk 'NR==2{print int($5)}')
  if [ "$u" -ge 95 ]; then
    say ПРОБЛЕМА ДИСК "$m занят на $u% — нет места"
  elif [ "$u" -ge 85 ]; then
    say ВНИМАНИЕ ДИСК "$m занят на $u%"
  else
    say ОК ДИСК "$m занят на $u%"
  fi
done

K=$( { dmesg -T; journalctl -k --since "-7 days" --no-pager; } 2>/dev/null )
K=$(echo "$K" | grep -oiE 'killed process [0-9]+ \([^)]+\)' | tail -1)
if [ -n "$K" ]; then
  say ПРОБЛЕМА УБИЙСТВА "ядро убивало процессы из-за памяти: $K"
else
  say ОК УБИЙСТВА "ядро процессы не убивало"
fi

if [ "$(systemctl is-active ollama)" = active ]; then
  R=$(ps -C llama-server -o rss= | awk '{s+=$1} END{printf "%.1f", s/1048576}')
  say ОК OLLAMA "служба работает, модель в памяти: $R ГБ"
else
  say ПРОБЛЕМА OLLAMA "служба не запущена"
fi
X=$(ps -eo user=,args= | grep "ollama serve" | grep -v grep | grep -vc '^ollama ')
```

```
if [ "$X" -gt 0 ]; then
  say ВНИМАНИЕ OLLAMA "ручных запусков ollama serve: $X — остановите их"
fi
U=/etc/systemd/system/ollama.service
S=$(grep -oE '(NUM_PARALLEL|CACHE_RAM)=[0-9]+' "$U" 2>/dev/null | tr '\n' ' ')
say ИНФО НАСТРОЙКИ "${S:-не найдены}"
say ИНФО FTP "vsftpd: $(systemctl is-active vsftpd)"
T=$(ps -eo rss=,comm= | awk '{a[$2]+=$1} END{for (k in a) print int(a[k]/1024), k}')
T=$(echo "$T" | sort -rn | head -3 | awk '{printf "%s %s МБ; ", $2, $1}')
say ИНФО ТОП-ПАМЯТЬ "$T"
T=$(ps -eo pcpu=,comm= --sort=-pcpu | head -3 | awk '{printf "%s %s%%; ", $2, $1}')
say ИНФО ТОП-ЦП "$T"
echo "ИТОГ:${SUM:- проблем с ресурсами не видно}"
```

Запустить (сейчас и каждый раз, когда что-то не так):

```
sudo bash ~/porfiry-check
```

Каждая строка начинается с оценки: `ОК`, `ВНИМАНИЕ` или `ПРОБЛЕМА`, строки `ИНФО` — справочные. Последняя строка — `ИТОГ:` со списком того, что не в порядке.

Строка	Что значит ВНИМАНИЕ / ПРОБЛЕМА
ПРОЦЕССОР	Мало ядер или нет AVX2 — процессор не тянет модель, нужна модель поменьше
НАГРУЗКА	Процессор занят больше, чем у него ядер, — всё работает медленно, очередь растёт
ПАМЯТЬ / ПОДКАЧКА	Памяти не хватает, система пишет её на диск — всё тормозит в разы
ДИСК	Диск заполнен — отсюда отказ FTP и ошибки записи. У вас всё на одном диске: будет одна строка про `/`
УБИЙСТВА	Ядро убивало процессы из-за нехватки памяти. Если там `llama-server` — это и есть «ответ одной буквой»
OLLAMA	Служба не запущена, или кроме службы работает ручной `ollama serve` — его надо остановить

Что сообщить разработчику: строку `ИТОГ:` и все строки с `ВНИМАНИЕ` / `ПРОБЛЕМА`, плюс строки `НАСТРОЙКИ` и `ТОП-ПАМЯТЬ`. Фотографировать не обязательно — можно переписать или продиктовать.

Шаг 3. Уменьшить память кэша Ollama

Кэш подсказок Ollama держит до 4 ГБ памяти. Снижаем до 1 ГБ — на скорость это почти не влияет. Два параллельных ответа (`OLLAMA_NUM_PARALLEL=2`) — уже щадящий режим, их не трогаем.

```
sudo sed -i 's/^Environment="LLAMA_ARG_CACHE_RAM=.*/Environment="LLAMA_ARG_CACHE_RAM=1024"/'
/etc/systemd/system/ollama.service
sudo systemctl daemon-reload && sudo systemctl restart ollama
sudo bash ~/porfiry-check
```

Ожидается строка `ИНФО  НАСТРОЙКИ: NUM_PARALLEL=2 CACHE_RAM=1024`.

Шаг 4. Проверочный файл: отвечает ли Ollama без Apache

Маленький PHP-файл задаёт модели вопрос так же, как это делает сайт, но без Apache, и считает, сколько строк потока пришло. После перезагрузки сервера /tmp очищается — тогда создайте файл заново.

Создать файл: введите команду, нажмите Enter, вставьте весь текст из рамки ниже, затем Enter и Ctrl+D:

```
cat > /tmp/probe.php
```

```
<?php
// Сколько строк потока PHP получает от Ollama — без Apache.
require getcwd() . '/vendor/autoload.php';
try {
    $client = new GuzzleHttp\Client(['timeout' => 120]);
    $body = $client->post('http://127.0.0.1:11434/api/chat', [
        'stream' => true,
        'json' => [
            'model' => 'qwen-demo',
            'options' => ['num_predict' => 1000, 'num_ctx' => 4096],
            'messages' => [['role' => 'user', 'content' => 'Назови пять цветов радуги']],
        ],
    ])->getBody();
    $lines = 0;
    $start = microtime(true);
    while (! $body->eof()) {
        if ($body->read(1) === "\n") {
            $lines++;
        }
    }
    echo 'строк: ' . $lines . ' за ' . round(microtime(true) - $start, 1) . " с\n";
} catch (Throwable $e) {
    echo 'ОШИБКА: ' . get_class($e) . ': ' . $e->getMessage() . "\n";
}
```

Во втором окне терминала откройте живой журнал Ollama (выйти — Ctrl+C):

```
sudo journalctl -u ollama -f -o cat | cut -c1-160
```

В первом окне запустите проверку — с ограничением 3 минуты, чтобы не висела бесконечно:

```
cd "$SITE" && sudo -u www-data timeout 180 php /tmp/probe.php; echo "код выхода: $?"
```

Результат	Что это значит и что делать
«строк: 20» и больше за 5–30 секунд	Ollama и транспорт исправны. Задайте вопрос в чате и посмотрите, полный ли ответ
«код выхода: 124»	За 3 минуты ответа не пришло — Ollama зависла или машине не хватает ресурсов. Запустите `sudo bash ~/porfiry-check` и посмотрите на второе окно с журналом
«ОШИБКА: …»	Перепишите текст ошибки

Шаг 5. Проверить чат и FTP

- Задайте вопрос в чате: полный ли ответ, одна буква или «вы в очереди».
- Загрузите файл по FTP: получилось ли.
- Если что-то не так — сразу запустите `sudo bash ~/porfiry-check`, пока проблема видна.

Откат правки контроллера

Если вы отключали проверку `connection_aborted()` командой `sed -i.bak-diag …`, вернуть как было:

```
cd "$SITE"
cp app/Http/Controllers/ChatController.php.bak-diag app/Http/Controllers/ChatController.php
sudo systemctl restart apache2
sudo systemctl try-restart php8.1-fpm
```

Что сообщить разработчику

- Вывод `sudo bash ~/porfiry-check`: строку ИТОГ, строки ВНИМАНИЕ / ПРОБЛЕМА, НАСТРОЙКИ и ТОП-ПАМЯТЬ.

- Результат проверочного файла (шаг 4): «строк: N», «код выхода: 124» или текст ошибки.
- Что было в журнале Ollama во время шага 4 (второе окно) — главное, есть ли там ошибки.
- Словами: что ответил чат и работает ли FTP.

> По этим данным станет ясно, в чём дело: в забитой очереди, в мощности машины (процессор, память, диск) или в самом обрыве потока — и какие настройки подобрать под вашу машину.