Ассистент Порфирий

Диагностика 2: всё зависает

Сброс очереди и проверка Ollama на сервере Astra

Что происходит

Если зависает И проверочный файл `/tmp/probe.php` без сайта, И чат («Сервер загружен, вы в очереди» — значит, не пришло даже первое слово), то сейчас Ollama не отвечает на новые запросы — ни сайту, ни PHP напрямую.

Самое вероятное: очередь Ollama забита старыми запросами от прошлых попыток (чат, check-site.py, нагрузочный тест). Каждый такой запрос держит одно из 6 мест и пишет до 1000 токенов впустую. Вторая версия — нехватка памяти: тогда всё идёт в десятки раз медленнее.

> Правку контроллера из шага 3 прошлой инструкции пока НЕ откатывайте — она нужна для проверки ниже.

В командах используется переменная `SITE` — путь к проекту. Строки, начинающиеся с `#`, вводить не нужно.

Шаг 1. Полный сброс

Очистить очередь Ollama, повисшие процессы PHP и устаревшие блокировки очереди сайта:

```
sudo systemctl restart ollama
sudo systemctl restart apache2
sudo systemctl try-restart php8.1-fpm
cd "$SITE" && sudo -u www-data php artisan cache:clear
```

Шаг 2. Память и состояние Ollama

Сфотографируйте вывод:

```
free -m
ollama ps
```

Шаг 3. Второй терминал — живой журнал Ollama

Откройте ещё одно окно терминала и оставьте в нём эту команду. Она показывает журнал Ollama в реальном времени (выйти — Ctrl+C):

```
sudo journalctl -u ollama -f -o cat | cut -c1-160
```

Шаг 4. Первый терминал — проверочный файл

Теперь с ограничением в 3 минуты, чтобы не висел бесконечно. Если файла `/tmp/probe.php` уже нет (после перезагрузки /tmp очищается) — создайте его заново по шагу 2 прошлой инструкции.

```
cd "$SITE" && sudo -u www-data timeout 180 php /tmp/probe.php; echo "код выхода: $?"
```

Результат	Что это значит и что делать
«строк: 20» и больше за 5–30 секунд	Сброс помог, транспорт исправен. Сразу задайте вопрос в чате: правка из шага 3 прошлой инструкции ещё стоит, и станет видно, полный ли теперь ответ
«код выхода: 124»	За 3 минуты ответа не пришло — Ollama зависла. Сфотографируйте второй терминал (журнал) и вывод `free -m`
Любой другой текст	Сфотографируйте его

Что прислать разработчику

- Фото вывода `free -m` и `ollama ps` (шаг 2).
- Фото результата проверочного файла (шаг 4).
- Фото второго терминала с журналом Ollama — во время шага 4 и во время вопроса в чате.
- Словами: что ответил чат после сброса — полный ответ, одна буква или «вы в очереди».

> По этим данным станет ясно, в чём дело: в забитой очереди, в памяти или в самом обрыве потока.