Ассистент Порфирий

Диагностика 2: всё зависает

Сброс очереди и проверка Ollama на сервере Astra

Что происходит

Если зависает И проверочный файл `/tmp/probe.php` без сайта, И чат («Сервер загружен, вы в очереди» — значит, не пришло даже первое слово), то сейчас Ollama не отвечает на новые запросы — ни сайту, ни PHP напрямую.

Самое вероятное: очередь Ollama забита старыми запросами от прошлых попыток (чат, check-site.py, нагрузочный тест). Каждый такой запрос держит одно из 6 мест и пишет до 1000 токенов впустую. Вторая версия — нехватка памяти: тогда всё идёт в десятки раз медленнее.

> Правку контроллера из шага 3 прошлой инструкции пока НЕ откатывайте — она нужна для проверки ниже.

В командах используется переменная `SITE` — путь к проекту. Строки, начинающиеся с `#`, вводить не нужно.

Шаг 1. Полный сброс

Очистить очередь Ollama, повисшие процессы PHP и устаревшие блокировки очереди сайта:

```
sudo systemctl restart ollama
sudo systemctl restart apache2
sudo systemctl try-restart php8.1-fpm
cd "$SITE" && sudo -u www-data php artisan cache:clear
```

Шаг 2. Память и состояние Ollama

Сфотографируйте вывод:

```
free -m
ollama ps
```

Шаг 3. Второй терминал — живой журнал Ollama

Откройте ещё одно окно терминала и оставьте в нём эту команду. Она показывает журнал Ollama в реальном времени (выйти — Ctrl+C):

```
sudo journalctl -u ollama -f -o cat | cut -c1-160
```

Шаг 4. Первый терминал — проверочный файл

Теперь с ограничением в 3 минуты, чтобы не висел бесконечно. Если файла `/tmp/probe.php` уже нет (после перезагрузки /tmp очищается) — создайте его заново по шагу 2 прошлой инструкции.

```
cd "$SITE" && sudo -u www-data timeout 180 php /tmp/probe.php; echo "код выхода: $?"
```

Результат	Что это значит и что делать
«строк: 20» и больше за 5–30 секунд	Сброс помог, транспорт исправен. Сразу задайте вопрос в чате: правка из шага 3 прошлой инструкции ещё стоит, и станет видно, полный ли теперь ответ
«код выхода: 124»	За 3 минуты ответа не пришло — Ollama зависла. Сфотографируйте второй терминал (журнал) и вывод `free -m`
Любой другой текст	Сфотографируйте его

Шаг 5. Хватает ли машине ресурсов

Если на одной виртуалке работают веб-сервер, FTP и модель, а у FTP перестают загружаться файлы — вероятно, машине не хватает ресурсов целиком. Две проверки, сфотографируйте вывод каждой.

Ресурсы машины: ядра, AVX2, память, подкачка, диск, нагрузка, и убивало ли ядро процессы из-за нехватки памяти:

```
nproc; grep -c avx2 /proc/cpuinfo; free -m; swapon --show; df -h / /var /usr /home; uptime;
sudo dmesg -T | grep -iE "out of memory|killed process" | tail -5
```

Кто ест память и процессор — лучше выполнить в момент, когда чат висит:

```
ps -eo pid,user,%cpu,%mem,rss,args --sort=-%mem | head -8 | cut -c1-120; echo; ps -eo
pid,user,%cpu,args --sort=-%cpu | head -6 | cut -c1-120
```

Что видно	Что это значит
Ядер мало, вторая цифра 0 (нет AVX2), `uptime` показывает нагрузку больше числа ядер	Процессор не тянет модель — нужна модель поменьше
`free -m`: почти нет свободной памяти, подкачка (swap) занята	Не хватает памяти — по второй команде видно, кто её забирает
В последней части первой команды есть `llama-server` или `ollama`	Ядро убивало модель из-за нехватки памяти — это и есть «ответ одной буквой»
Диск занят на 95–100%	Отсюда и отказ FTP, и ошибки записи в кэш

Два параллельных ответа (`OLLAMA_NUM_PARALLEL=2`) — уже щадящий режим, его менять не нужно.

Шаг 6. Уменьшить память кэша Ollama

Кэш подсказок Ollama держит до 4 ГБ памяти. Снижаем до 1 ГБ — на скорость это почти не влияет. Можно сделать сразу, не дожидаясь разбора фото:

```
sudo sed -i 's/^Environment="LLAMA_ARG_CACHE_RAM=.*/Environment="LLAMA_ARG_CACHE_RAM=1024"/'
/etc/systemd/system/ollama.service
sudo systemctl daemon-reload && sudo systemctl restart ollama
grep -E "NUM_PARALLEL|CACHE_RAM" /etc/systemd/system/ollama.service
```

Ожидается: `OLLAMA_NUM_PARALLEL=2` и `LLAMA_ARG_CACHE_RAM=1024`. Затем проверьте чат и загрузку файлов по FTP.

Что прислать разработчику

- Фото вывода `free -m` и `ollama ps` (шаг 2).
- Фото результата проверочного файла (шаг 4).
- Фото второго терминала с журналом Ollama — во время шага 4 и во время вопроса в чате.
- Фото обеих команд шага 5.
- Словами: что ответил чат после сброса и после шага 6 — полный ответ, одна буква или «вы в очереди»; заработала ли загрузка по FTP.

> По этим данным станет ясно, в чём дело: в забитой очереди, в мощности машины (процессор, память, диск) или в самом обрыве потока — и какие настройки подобрать под вашу машину.