Порфирий — обновление: научный чат и очередь

Одна инструкция на всё обновление. Порядок: перенести файлы (раздел 1), затем по одному скрипту на сервере 172.19.101.170 (раздел 2) и на веб-сервере 172.19.101.69 (раздел 4). Каждый скрипт печатает строки `ОК` / `ВНИМАНИЕ` / `ПРОБЛЕМА` и в конце `ИТОГ`; при `ПРОБЛЕМА` он останавливается и пишет, что сделать. Повторный запуск безопасен.

Что меняется

- Чат «Программирование» становится чатом **«Научный»**: расчёты, математика, физика, химия, инженерные задачи. Новое имя везде: вкладка «Научный», адрес `/chat/science`, настройки сайта `LLM_SCIENCE_*`, модель `science` на сервере .170.
- На сервере .170 вместо Qwen3-Coder-Next работает **Qwen3.6 35B-A3B** — та же модель, что на офисном сервере .171. Перед ответом она рассуждает: точнее в расчётах. Скачивать ничего не нужно: модель берётся с сервера .171.
- **Очередь.** Каждый чат отвечает одному человеку за раз. Остальные видят на месте ответа карточку очереди: крупный номер места, строку «Перед вами 2 запроса · ждёте 0:42» и полосу продвижения очереди (подробно — раздел 5).
- **Строгий стиль** в обоих чатах: без эмодзи, восклицаний и разговорных вступлений.
- Памятка для сотрудников `ВОЗМОЖНОСТИ.pdf` (в пакете) — раздать после обновления.

1. Перенести файлы (вручную)

Что	Откуда	Куда
`update-science.tar` (0,5 МБ)	компьютер, `D:\porfiry-media`	серверы .170 и .69, папка `/opt/porfiry`
модель — папка `models-office` (23 ГБ)	сервер .171, `/opt/porfiry/models-office`	сервер .170, папка `/opt/porfiry`

`update-science.tar` — WinSCP или флешкой. Затем на **каждом** из двух серверов (.170 и .69) распаковать и проверить — ожидается слово `цело`:

```
cd /opt/porfiry && sudo tar -xf update-science.tar
cd /opt/porfiry/update-science && sha256sum -c --quiet SHA256SUMS.txt && echo "цело"
```

Модель на сервер .170 — один из двух вариантов (весь архив .171 не нужен, только модель):

- **Вариант А, по сети (быстрее).** На сервере .170 (вместо `ИМЯ` — ваш пользователь на .171; спросит его пароль):

```
sudo scp -r ИМЯ@172.19.101.171:/opt/porfiry/models-office /opt/porfiry/
```

- **Вариант Б, без сети.** Перенесите на .170 в `/opt/porfiry` архив `server-171-office.tar` (24 ГБ) — скрипт из раздела 2 сам распакует из него модель.

2. Сервер 172.19.101.170 — научный чат

```
sudo bash /opt/porfiry/update-science/server-170/science-170.sh
```

Скрипт по шагам: находит модель (папку `models-office` или архив .171), проверяет её файлы (23 ГБ читаются несколько минут), подключает модель к Ollama, ставит новую службу Ollama и прогрев,

называет модель `science`, удаляет старые `code` и `qwen3-coder-next`, загружает модель в память и задаёт пробный вопрос. Первая загрузка с диска — до 15 минут. Ожидается:

```
OK  ответ модели: 4
ИТОГ: OK — научный чат на сервере .170 готов
```

Когда чат проверен в браузере (раздел 4), освободите место старой модели (51 ГБ):

```
sudo rm -rf /opt/porfiry/models-code
```

3. Сервер 172.19.101.171 — офисный (по желанию)

Модель отвечает по одному запросу, поэтому Ollama не должна держать память под пять одновременных ответов. После команд модель перечитается с диска (несколько минут):

```
U=/etc/systemd/system/ollama.service
sudo sed -i 's/OLLAMA_NUM_PARALLEL=5/OLLAMA_NUM_PARALLEL=1/' $U
sudo systemctl daemon-reload && sudo systemctl restart ollama porfiry-warmup
```

4. Веб-сервер 172.19.101.69 — сайт

Вместо `/путь/к/сайту` — папка, где лежит `artisan`:

```
sudo bash /opt/porfiry/update-science/server-69/update-web.sh /путь/к/сайту
```

Скрипт сохраняет копию заменяемых файлов и строк `LLM_` из `.env` в `/opt/porfiry/backup-science` (для отката), кладёт 14 новых файлов чата, переименовывает в `.env` строки `LLM_CODE_…` в `LLM_SCIENCE_…`, включает очередь по одному ответу (`LLM_OFFICE_SLOTS=1`, `LLM_SCIENCE_SLOTS=1`, на ответ — до 45 минут, в очереди — до 30 минут), пересобирает кэши, перезапускает Apache и проверяет, что адрес `/chat/science` работает. Ожидается `ИТОГ: OK — сайт обновлён`. Затем полная проверка (вопросы обоим чатам, «Стоп», документы, ГОСТы):

```
cd /opt/porfiry/update-science/server-69
sudo -u www-data python3 check-web.py --site /путь/к/сайту
```

Затем в браузере откройте `http://172.19.101.69/chat` и обновите страницу (Ctrl+F5):

1. Вкладки — «Офисный» и «Научный». В «Научном» подсказки о расчётах.
2. В «Научном» спросите «Сколько будет 2+2?». Сначала «Модель рассуждает… 0:05» со счётчиком, затем ответ без эмодзи.
3. Очередь: откройте чат во втором браузере (или в окне инкогнито) и задайте вопрос в том же чате, пока идёт первый ответ. Во втором окне появится карточка: номер 1, «Вы следующий», «Перед вами 1 запрос · ждёте 0:12». Когда первый ответ закончится, карточка на секунду покажет «Ваша очередь», и начнётся второй ответ.

5. Как работает очередь

- У каждого чата своя очередь: офисный и научный друг другу не мешают.
- Отвечает один запрос; остальные ждут строго по порядку.
- Что видит человек: 1. Очереди нет — карточки нет: сразу «Модель читает вопрос… 0:05» с крутящимся значком (в научном чате затем «Модель рассуждает… 1:20»). 2. Есть очередь — карточка: номер места (первому — «Вы следующий»), «Перед вами N запросов · ждёте 0:42», полоса и подпись «Очередь сдвинулась на 2 из 5». 3. Очередь подошла — вместо номера галочка, «Ваша очередь», полоса заполнена. 4. Пошёл ответ — карточка исчезает, идёт текст ответа.
- «Стоп» в очереди снимает запрос с очереди, остальные сдвигаются.
- Настройки в `.env` сайта (после правки — `sudo -u www-data php artisan config:cache` и перезапуск apache2):

Настройка	Сейчас	Что значит
`LLM_OFFICE_SLOTS`, `LLM_SCIENCE_SLOTS`	1	сколько ответов идёт сразу в чате
`LLM_QUEUE_MAX_WAIT`	1800	сколько секунд можно ждать в очереди
`LLM_QUEUE_MAX_WAITING`	20	сколько человек может ждать (больше — «Очередь переполнена»)
`LLM_ANSWER_TIMEOUT`	2700	сколько секунд даётся на один ответ
`LLM_MAX_PER_IP`	8	вопросов сразу с одного компьютера

6. Если что-то пошло не так

- Скрипт написал `ПРОБЛЕМА` — сделайте, что написано в этой строке, и запустите его снова.
- Ollama на .170 не отвечает — журнал: `sudo journalctl -u ollama -n 30 --no-pager`.
- **Откат сайта** — всё как до обновления (файлы и строки `LLM_` из `.env`):

```
sudo bash /opt/porfiry/update-science/server-69/rollback-science.sh /путь/к/сайту
```

- **Откат сервера .170** — вернуть Qwen3-Coder-Next можно, пока не удалена папка `/opt/porfiry/models-code` (раздел 2):

```
cd /opt/porfiry/models && sudo bash install-ollama.sh code
```